

Projeto Final - Aprendizagem de Máquina



Modelo: TabICL v2

João Pedro Miranda da Silva

Maria Clara Falcão Guerra Barretto

Vinícius Limeira Valença

2026.1

Universidade Federal de Pernambuco (UFPE) - CIn



1. Etapa 1 - Fundamentação teórica do modelo
2. Etapa 2 - Estudo experimental


Etapa 1 - Fundamentação teórica do modelo



- Algoritmos baseados em árvores (GBDTs) possuem ampla adoção na modelagem de dados tabulares não homogêneos.
- O avanço dos *Foundation Models* levanta a possibilidade de aplicar o paradigma do *In-Context Learning* (ICL) ao domínio tabular.
- **Objetivo:** Permitir que um modelo pré-treinado infira padrões em tempo real usando instâncias de treino como contexto no *prompt*.
- **Vantagem esperada:** Mitigar a necessidade de treinamento local (*Gradient Descent*) e busca exaustiva por hiperparâmetros.



- **Hipótese principal:** A relação entre variáveis preditoras (X) e a resposta (Y) pode ser formulada como um problema de modelagem de sequência.
- **Pré-treinamento:** O modelo é exposto a uma diversidade de superfícies de decisão, incorporando um algoritmo de aprendizado genérico em sua estrutura de pesos.
- **Inferência:** As amostras de treino fornecidas funcionam como exemplos de demonstração (*prompt*).
- **Mecanismo:** A auto-atenção correlaciona a nova observação aos vizinhos contextuais que definem a fronteira de decisão da tarefa.



O núcleo da arquitetura é baseado no framework *Transformer*:

- **Entrada bruta e *Embeddings*:** Variáveis numéricas são escalonadas dinamicamente e categóricas mapeadas internamente num espaço contínuo.
- **Atenção Cruzada:** A estrutura incorpora camadas de atenção para permitir o fluxo de informações entre as instâncias de treino e teste.
- **Classificação Final:** Para suportar tarefas multiclasse, a camada final aplica Softmax sobre os *logits* gerados pelas representações contextuais.



- **Função de perda:** Entropia Cruzada otimizada no pré-treinamento sintético:

$$\mathcal{L}(\theta) = -\mathbb{E}_{\mathcal{D} \sim p(\mathcal{D})} \left[\frac{1}{|D_{test}|} \sum_{(x_i, y_i) \in D_{test}} \log P_{\theta}(y_i \mid x_i, D_{train}) \right]$$

- **Regularização:** *Dropout* estocástico nas camadas de atenção e *clipping* nas *features*:

$$\tilde{h} = \text{Dropout}(\text{Attention}(Q, K, V)), \quad x_{clip} = \max(\min(x, c), -c)$$

- **Etapa de inferência:** Passagem *forward* (In-Context), sem atualização de pesos ($\Delta\theta = 0$):

$$\hat{y}_{test} = \arg \max_{y \in \mathcal{Y}} P_{\theta}(y \mid x_{test}, D_{train})$$



Operacao	Tempo	Memória	Observação
Treino	$\mathcal{O}(1)$	$\mathcal{O}(n \cdot p)$	Zero-Shot: contexto retido na RAM
Inferência	$\mathcal{O}(n^2 \cdot p)$	$\mathcal{O}(n^2 \cdot p)$	Custo dominado pela Matriz de Atenção

Pico de memória observado: > 50 GB em datasets do regime grande.

Etapa 1: Hiperparâmetros Principais e Faixas



Hiperparâmetro	Faixa (Optuna)	Justificativa do Relatório	Efeito esperado
<code>n_estimators</code>	[4, 32] (int)	Tamanho do <i>ensemble</i> de contexto.	Reduz variância; eleva tempo de inferência e uso de RAM.
<code>softmax_temperature</code>	[0.3, 1.5] (float)	Calibração simulando <i>annealing</i> .	Modula viés-variância (suaviza a entropia de confiança).
<code>outlier_threshold</code>	[2.0, 6.0] (float)	Limiar numérico de <i>clipping</i> .	Afeta robustez a ruídos; limiares rígidos elevam o viés.
<code>average_logits</code>	{True, False} (bool)	Estratégia de agregação.	Estabiliza variância amortecendo impacto de <i>outliers</i> .
<code>norm_methods</code>	{quantile, ...} (cat.)	Escalonamento do <i>embedding</i> .	Altera a geometria da atenção e o viés das <i>features</i> .



- 2023: [Hollmann et al.] *TabPFN* (ICLR). Fundamentou o uso de Transformers para bases pequenas em um único *forward pass*.
- 2024: [Hölmüller et al.] *Better by default: Strong pre-tuned MLPs and boosted trees on tabular data* (NeurIPS). Demonstrou que GBDTs com bons defaults meta-aprendidos são competitivos sem tuning extenso.
- 2025: [Qu et al.] *TabICL* (ICML). Modelo de *In-Context Learning* escalável para dados tabulares densos via arquitetura coluna-depois-linha.
- 2026: [Qu et al.] *TabICLv2* (arXiv:2602.11139). Expansão com *scalable softmax*, gerador sintético diversificado e otimizador Muon.

O **TabICLv2** se diferencia por: prescindir totalmente de engenharia de features e evitar horas computacionais para busca de hiperparâmetros locais.



- **Restrições de escala (n , p):** A complexidade assintótica quadrática do mecanismo de atenção restringe a aplicação do modelo em regimes massivos ($n > 10.000$).
- **Gargalo Computacional:** Nessas grandes escalas, os modelos baseados em árvore continuam oferecendo um balanço imbatível de tempo e eficiência de RAM.
- **Ausência de *Tuning* local:** Embora dispense a parametrização manual pesada e imputações prévias, o modelo cede controle empírico fino em bases que exigem tratamentos de esparsidade específicos.

Etapa 2 - Estudo experimental




- **Datasets:** 30 bases da suíte TabArena-v0.1 (3 pequenos + 17 médios + 10 grandes).
- **Split:** Validação *Hold-out* (70/30) estratificada por classe, seed fixa (42).
- **Busca:** *Optuna (TPE)* com 20 *trials* (limitado a 2 horas) para os GBDTs Tunados.
- **Métricas:** *AUC-OvO* (robusta a desbalanceamento), ACC, G-Mean, Cross-Entropy e tempo total.
- **Concorrentes:** 9 modelos testados = TablCL + 3 baselines Default + 3 baselines Tunados + AutoGluon (Default e Extreme 4h).



Sistema	AUC OvO	Ranking médio	Tempo (s)
AutoGluon Extreme 4h	0.9108 ± 0.125	2.35	1831.0
TabICL (Grupo)	0.9090 ± 0.115	2.57	48.5
AutoGluon Default	0.9094 ± 0.122	3.60	1596.0
CatBoost Tuned	0.9002 ± 0.134	4.10	782.0
CatBoost Default	0.8989 ± 0.120	4.40	23.0
XGBoost Tuned	0.8982 ± 0.128	4.60	359.0
LightGBM Tuned	0.8977 ± 0.141	4.85	2899.0
LightGBM Default	0.8938 ± 0.138	5.30	32.0
XGBoost Default	0.8897 ± 0.132	6.10	1.0

Posição do modelo do grupo no ranking: [2º de 9]. O TabICL manteve-se no topo absoluto do Ranking Médio junto do *AutoGluon Extreme*.

Etapa 2: Ranking médio e diagrama de diferença crítica



- Teste Não-Paramétrico de Friedman ($p \approx 0.001$, $p < 0.05$); rejeição da hipótese nula global.
- Pós-hoc Nemenyi: Grupo estatisticamente líder destacado em negrito (linha horizontal conexa).

Etapa 2: Comparação Bayesiana (signed-rank com ROPE)



Comparação	p(TabICL melhor)	p(equivalente)	p(pior)
TabICL vs AutoGluon extreme	0,0000	0,9991	0,0008
TabICL vs AutoGluon default	0,0121	0,9878	0,0000
TabICL vs CatBoost Tuned	0,2368	0,7631	0,0000
TabICL vs CatBoost TD	0,1353	0,8646	0,0000
TabICL vs LightGBM Tuned	0,0273	0,9726	0,0000
TabICL vs LightGBM TD	0,3076	0,6923	0,0000
TabICL vs XGBoost Tuned	0,1018	0,8982	0,0000
TabICL vs XGBoost TD	0,4276	0,5723	0,0000

ROPE = 0,01 em AUC OvO; gerado por baycomp. O TabICL denota impressionantes 99,9% de probabilidade amostral de equivalência estatística com o AutoML de 4 horas.

Etapa 2: Análise por regime (tamanho e classes)




■ Tamanho do Dataset

- *Small*: GBDTs (~ 0.860) lideram.
- *Medium*: TabICL lidera (0.943).
- *Large*: Equivalência técnica.

■ Número de Classes

- *Multiclasse*: TabICL destroça baselines e lidera (0.948).
- *Binário*: Competição acirrada.






■ Proporção Categórica


Alta dominância numérico-contínua favorece enormemente os tensores do TablCL. Bases puramente categóricas retornam vantagem à heurística do CatBoost.

■ Missing: NaN

O TablCL degrada perante presença extensiva de NaNs (0.848) por ausência de imputador direcional explícito em nó da árvore.



Etapa 2: Custo vs Desempenho



O AutoGluon Extreme define o teto prático; GBDTs em default formam o piso barato. O TabICL consolida o balanço otimizado invertendo a curva Pareto.



- **Brilha em:** Regime Médio Numérico (exemplo: *jungle*, $\text{delta} = +0.045$). O contexto é absorvido estritamente sem estouro de VRAM.
- **Fracassa em:** Regime com alta taxa de NaNs e Alta Esparsidade (exemplo: *anneal*, $\text{delta} = -0.061$).
- **Causa provável:** Ausência de nós de decisão dedicados para valores faltantes categóricos, onde codificadores externos prejudicam o processamento da atenção.



- **Quanto AutoML "compra" em termos de AUC OvO?**
Delta médio: +**0.0018** de ganho global marginais nas 30 bases analisadas.
- **Custo extra de AutoGluon Extreme vs modelo TabICL:**
Um fator de latência de **38×** a mais de execução (minutos vs horas computacionais).
- **Quando o ganho de AutoML é relevante na prática?**
Apenas quando o dataset é gigantesco e altamente ruidoso (Regime *Large* Esperso com restrições orçamentárias corporativas amplas).



- **Posição do modelo:** O paradigma Zero-Shot via inferência local em contexto (ICL) atinge a Fronteira Estado da Arte.
- **Pontos fortes:** Execução determinística em ciclo curto de *forward pass*; superioridade notável perante alvos Multiclasse.
- **Limites:** Intensivo em hardware (*OOM* frequente em limites de n, p); carência na interpretabilidade formal dos fatores.
- **Próximos passos:** Expansão da calibração de temperatura bayesiana e mecanismos de compressão linear de atenção.

Agradecemos pela Atenção!

Repositório: [github.com/grupo/projeto-am]

**Referências principais: Qu et al. (2025/2026),
Hölmüller et al. (2024), Demšar (2006).**

Dúvidas ou Questionamentos?